

PROPOSTA DE PESQUISA APLICADA
E INOVAÇÃO TECNOLÓGICA

AI-Photon

Plataforma de Inteligência Artificial para Imagem Espectral Quantitativa em Tomografia por Contagem de Fótons Aplicada à Oncologia

Visão central: construir uma plataforma capaz de **quantificar**, **caracterizar**, **prever** e **acompanhar** a doença oncológica a partir do dado espectral nativo da tomografia por contagem de fótons (PCCT), combinando imagens multienergéticas, dados clínicos, física de imagem e Inteligência Artificial.

Proponente:	Grupo de Saúde Digital – Universidade Estadual do Ceará (UECE)
Empresa-alvo/parceira:	Siemens Healthineers
Parceiro clínico:	Parceiro clínico de diagnóstico por imagem / Omnima- gem
Coordenação proposta:	Prof. Bonfim Amaro Jr.
Casos clínicos iniciais:	câncer de pulmão, metástases hepáticas de câncer co- lorretal e massas renais
Duração sugerida:	30 meses
Natureza:	Pesquisa aplicada, experimentação tecnológica, valida- ção clínica e prototipação de software

Fortaleza – Ceará – Brasil
2026

Sumário

1	Resumo executivo	4
2	Contexto e oportunidade tecnológica	5
2.1	O que é a tomografia por contagem de fótons?	5
2.2	O que significa quantificação espectral em oncologia?	5
2.3	Por que Inteligência Artificial?	6
3	Motivação estratégica para a Siemens Healthineers	6
4	Problema de pesquisa	7
5	Hipótese e tese tecnológica do projeto	7
6	Objetivos	7
6.1	Objetivo geral	7
6.2	Objetivos específicos	8
7	Casos clínicos demonstradores e estratégia de expansão	8
7.1	Demonstradores iniciais	8
7.2	Expansão planejada	9
8	Arquitetura geral da solução	9
8.1	Princípios arquiteturais	9
9	Metodologia técnica detalhada	9
9.1	Etapa 1 – Ingestão, organização e governança dos dados	9
9.2	Etapa 2 – Controle de qualidade automático	11
9.3	Etapa 3 – Segmentação automática	11
9.4	Etapa 4 – Registro multimodal e longitudinal	11
9.5	Etapa 5 – Ultra-baixa dose com preservação quantitativa	12
9.6	Etapa 6 – Quantificação espectral e calibração	12
9.7	Etapa 7 – Radiômica espectral e harmonização	12
9.8	Etapa 8 – Redução de contraste iodado	13
9.9	Etapa 9 – Motor de biomarcadores	13
9.10	Etapa 10 – AI Predictive Response	13
9.11	Etapa 11 – AI Longitudinal Tracking	14
9.12	Etapa 12 – Incerteza e confiança	14
10	Plataforma de software	14
10.1	Camadas	14
10.2	Stack tecnológico sugerido	15
10.3	MLOps e rastreabilidade	15
11	Base de dados e estratégia amostral	15
11.1	Acesso ao equipamento como parte da estratégia	15
11.2	Fases da base	16
11.3	Faixas amostrais para planejamento	16
11.4	Regionalidade como questão científica	16

12 Desenho experimental e validação	17
12.1 Princípio geral	17
12.2 Métricas	17
12.3 Separação correta dos dados	17
12.4 Validação de modelos com poucas amostras	17
12.5 Metas técnicas provisórias	17
13 Work Packages	18
14 Cronograma sugerido	19
15 MVP e evolução tecnológica	19
15.1 MVP 1 – Quantificação espectral automatizada reprodutível	19
15.2 MVP 2 – Imagem quantitativa com menor custo de aquisição	19
15.3 MVP 3 – Predição pré-tratamento	19
15.4 MVP 4 – Acompanhamento longitudinal adaptativo	19
15.5 Visão de produto	20
16 Equipe e responsabilidades	20
16.1 Divisão institucional sugerida	20
17 Ética, LGPD, segurança e regulação	21
17.1 Ética em pesquisa	21
17.2 Proteção de dados	21
17.3 Software como dispositivo médico	21
18 Riscos e estratégias de mitigação	21
19 Indicadores de sucesso	21
19.1 Científicos	21
19.2 Tecnológicos	21
19.3 Clínico-operacionais	21
19.4 Inovação	23
19.5 Formação	23
20 Entregáveis consolidados	23
21 Estrutura de orçamento	23
22 Propriedade intelectual e transferência tecnológica	24
23 Diferenciais da proposta	24
24 Cenário demonstrativo	24
25 Perguntas científicas que podem gerar publicações	25
26 Plano de decisão Go/No-Go	26
27 Resultados esperados e impacto	26
27.1 Para pacientes	26
27.2 Para serviços de radiologia e oncologia	26
27.3 Para a Siemens Healthineers	27
27.4 Para o Ceará e para o grupo proponente	27

28 Mensagem recomendada para apresentação à empresa	27
29 Próximos passos recomendados	27
A Checklist para fechar a versão a ser enviada à Siemens	29
B Glossário didático	29

1 Resumo executivo

A tomografia computadorizada por contagem de fótons (PCCT, *photon-counting computed tomography*) representa a maior mudança de arquitetura de detectores de TC das últimas décadas. Ao contar fótons individualmente e medir a energia de cada um, o PCCT entrega, em todo exame de rotina, resolução espacial submilimétrica, ausência de ruído eletrônico, redução de dose e, sobretudo, **informação espectral nativa**: a possibilidade de decompor os tecidos em materiais, quantificar iodo em mg/mL e reconstruir imagens monoenergéticas virtuais sem protocolo especial.

Em oncologia, essa capacidade abre um caminho concreto: transformar a TC, hoje interpretada de forma majoritariamente visual e mensurada por critérios dimensionais como o RECIST, em um exame **quantitativo, reprodutível e comparável ao longo do tempo**. Parte desse fluxo já é automatizada em soluções comerciais modernas. Assim, a oportunidade de P&D proposta neste projeto não é apenas “processar imagens de PCCT”, mas evoluir para uma **camada de inteligência oncológica espectral, quantitativamente validada e consciente de incerteza**.

O projeto AI-Photon propõe uma plataforma computacional modular que integre imagens espectrais de PCCT, dados clínicos e laboratoriais, informações de tratamento e modelos físicos de formação de imagem. A solução será estruturada para produzir cinco capacidades progressivas:

1. **AI Auto-Quant**: automação reprodutível do fluxo quantitativo espectral, da entrada DICOM aos mapas de materiais, biomarcadores e relatório;
2. **AI Ultra-Low-Dose**: redução de dose de radiação por métodos de reconstrução e aprendizado orientados à preservação do biomarcador, e não apenas da aparência visual;
3. **AI Spectral Biomarkers**: radiômica espectral para caracterização de tecido tumoral, carga de doença e heterogeneidade intratumoral;
4. **AI Predictive Response**: previsão de resposta terapêutica a partir do exame basal, dados clínicos e biomarcadores espectrais;
5. **AI Longitudinal Tracking**: acompanhamento quantitativo entre ciclos de tratamento, atualizando as previsões com os dados observados de cada paciente e mantendo o especialista humano como responsável pela decisão clínica.

Os casos demonstradores iniciais recomendados são três, escolhidos para que cada um explore uma capacidade distinta do PCCT com o mesmo núcleo tecnológico: **câncer de pulmão** (detecção e caracterização de nódulos em ultra-baixa dose), **metástases hepáticas de câncer colorretal** (mapas de iodo como biomarcador de perfusão e resposta) e **massas renais** (caracterização não invasiva por decomposição de materiais). A arquitetura, entretanto, será projetada como **órgão-configurável**, para posterior extensão a outros sítios tumorais.

Como resultado, espera-se entregar um **protótipo integrado validado em ambiente clínico**, algoritmos de IA e quantificação espectral, uma base de dados estruturada, protocolos de validação, publicações, ativos de propriedade intelectual e uma rota técnica para eventual transformação do protótipo em software de apoio à decisão e/ou módulo incorporável ao ecossistema de soluções da Siemens Healthineers.

Em termos simples. O projeto não pretende substituir o radiologista ou o oncologista. A proposta é construir uma “camada inteligente” que transforme as imagens espectrais e os dados do paciente em medidas quantitativas, previsões e intervalos de confiança, diminuindo tarefas repetitivas e fornecendo informação adicional para a decisão do especialista.

2 Contexto e oportunidade tecnológica

2.1 O que é a tomografia por contagem de fótons?

Os tomógrafos convencionais utilizam detectores de integração de energia: os raios X são convertidos em luz visível por um cintilador e, em seguida, em sinal elétrico, somando a energia de todos os fótons de uma vez. No PCCT, um semiconductor (telureto de cádmio, no caso do NAEOTOM Alpha) converte cada fóton diretamente em pulso elétrico. Cada fóton é contado individualmente e classificado em faixas (*bins*) de energia.

Essa mudança de arquitetura produz quatro consequências físicas com impacto clínico direto: eliminação do ruído eletrônico, resolução espacial de até cerca de 0,2 mm, melhor eficiência de dose e **espectralidade nativa em todo exame**. Para um material como o iodo, a assinatura de atenuação em função da energia permite separá-lo dos demais tecidos:

$$\mu(E) = a_1 f_1(E) + a_2 f_2(E), \quad (1)$$

em que $\mu(E)$ é o coeficiente de atenuação, f_1 e f_2 são funções de base (por exemplo, efeito fotoelétrico e espalhamento Compton, ou pares de materiais como água e iodo) e a_1 , a_2 são os coeficientes estimados voxel a voxel. A partir dessa decomposição obtêm-se imagens monoenergéticas virtuais (VMI), mapas de concentração de iodo e imagens virtuais sem contraste (VNC).

Em termos simples. A TC convencional mede “quanto o feixe foi atenuado”. O PCCT mede também “em quais energias”, o que funciona como uma impressão digital dos materiais. Com isso, o mesmo exame informa não só a forma das estruturas, mas quanto iodo (e, portanto, quanto fluxo sanguíneo funcional) existe em cada região de um tumor.

2.2 O que significa quantificação espectral em oncologia?

De maneira conceitual, a imagem oncológica quantitativa baseada em PCCT precisa responder a três perguntas:

1. **Onde está a doença?** (detecção e segmentação de lesões)
2. **Quanto de doença existe e com quais características teciduais?** (volume, carga tumoral, concentração de iodo, heterogeneidade)
3. **Como essas medidas evoluem ao longo do tratamento?** (resposta, progressão, estabilidade)

Se $c_I(x, y, z)$ representa a concentração de iodo estimada em cada voxel, a carga funcional de uma lesão Ω pode ser expressa por:

$$Q_\Omega = \int_{\Omega} c_I(x, y, z) dV, \quad (2)$$

e a carga tumoral total do paciente pela soma sobre as lesões rastreadas:

$$TB = \sum_{\ell} V_{\ell}, \quad TB_I = \sum_{\ell} Q_{\ell}. \quad (3)$$

Medidas desse tipo, quando obtidas de forma reprodutível, permitem comparar exames de datas diferentes com muito mais sensibilidade do que a medição de diâmetros.

2.3 Por que Inteligência Artificial?

A IA pode atuar em praticamente todas as etapas que antecedem ou complementam a quantificação espectral:

- segmentação automática de órgãos e lesões;
- registro deformável de exames adquiridos em diferentes momentos;
- redução de ruído e reconstrução em regimes de baixa dose e baixo contraste;
- estabilização e harmonização de atributos radiômicos;
- previsão de resposta terapêutica a partir do exame basal;
- atualização individualizada das previsões entre ciclos de tratamento;
- detecção de exames fora do padrão;
- estimação e propagação da incerteza.

O valor científico está em fazer isso **sem sacrificar a quantificação**. Uma imagem visualmente agradável não é suficiente. O algoritmo deve preservar concentrações de iodo, números de TC em VMI, volumes e atributos radiômicos, pois são essas as grandezas que sustentam a decisão clínica.

3 Motivação estratégica para a Siemens Healthineers

A Siemens Healthineers é pioneira e líder mundial em PCCT: o NAEOTOM Alpha foi o primeiro tomógrafo comercial por contagem de fótons do mundo, e a classe NAEOTOM (Alpha.Peak, Alpha.Pro e Alpha.Prime) ampliou o alcance da tecnologia a diferentes perfis de instituição [1, 2]. O ecossistema syngo e as ferramentas espectrais nativas do equipamento já automatizam reconstrução, geração de VMI, mapas de iodo e fluxos de leitura.

Essa realidade define corretamente a oportunidade de P&D: a proposta **não deve duplicar capacidades maduras** do fabricante. O foco será criar e prototipar a próxima camada de inteligência sobre o dado espectral que o equipamento entrega:

- quantificação oncológica reprodutível de ponta a ponta, com rastreabilidade;
- protocolos de ultra-baixa dose e de redução de contraste validados por erro em biomarcador, e não apenas por qualidade visual;
- biomarcadores espectrais de caracterização tecidual e resposta;
- previsão pré-tratamento e acompanhamento longitudinal adaptativo;
- quantificação explícita de incerteza;
- generalização para população, protocolos e prática clínica latino-americana;
- integração de imagem espectral, biomarcadores laboratoriais e variáveis clínicas.

Em termos simples. O posicionamento mais forte para uma conversa com a Siemens é: “não queremos reconstruir o que o NAEOTOM já faz; queremos pesquisar como transformar o dado espectral que ele produz em decisão oncológica quantitativa, preditiva e menos onerosa em dose, contraste e trabalho humano”.

4 Problema de pesquisa

O problema central pode ser formulado da seguinte maneira:

Como combinar Inteligência Artificial, imagens espectrais de PCCT, dados clínicos e modelos físicos de formação de imagem para transformar a TC oncológica em um exame quantitativo, preditivo e longitudinal, reduzindo dose, contraste e esforço humano sem perder validade clínica?

Esse problema se desdobra em seis dificuldades científicas:

1. **Variabilidade anatômica e temporal:** órgãos e tumores mudam de posição, forma e volume entre aquisições e ao longo do tratamento;
2. **Regime de baixa estatística:** protocolos de ultra-baixa dose e de baixo contraste elevam o ruído e degradam a estimativa espectral;
3. **Poucos dados rotulados:** bases clínicas de PCCT ainda são pequenas e recentes em comparação com grandes bases de radiologia convencional;
4. **Estabilidade do biomarcador:** concentração de iodo, VMI e atributos radiômicos variam com protocolo, reconstrução, kernel e fase de contraste;
5. **Erro acumulado:** pequenas imprecisões em segmentação, registro, calibração ou decomposição de materiais podem se propagar até o biomarcador final;
6. **Generalização:** modelos podem perder desempenho diante de novos protocolos, populações e versões de equipamento ou software.

5 Hipótese e tese tecnológica do projeto

A hipótese central é que uma arquitetura híbrida, combinando **modelos físicos + métodos estatísticos + aprendizado de máquina**, será mais robusta para quantificação espectral oncológica do que uma estratégia puramente baseada em redes neurais de ponta a ponta.

A tese tecnológica do projeto é:

A imagem oncológica pode ser transformada em um processo de ciclo fechado: **Quantificar → Prever → Tratar → Medir → Aprender**, no qual o modelo populacional é gradualmente ajustado pelas observações do próprio paciente.

No exame basal, a plataforma utilizará biomarcadores espectrais e padrões populacionais para estimar a resposta esperada. Após cada ciclo de tratamento, utilizará o PCCT de reavaliação para medir a evolução real da carga tumoral e da perfusão. Nos ciclos seguintes, a previsão poderá incorporar tanto o conhecimento populacional quanto a trajetória individual já observada.

6 Objetivos

6.1 Objetivo geral

Criar e validar uma plataforma computacional baseada em Inteligência Artificial para automação, quantificação, predição e acompanhamento longitudinal em oncologia com PCCT, integrando imagens espectrais, dados clínicos e modelos físicos, de modo a reduzir dose de radiação,

volume de contraste e tempo de processamento, produzir biomarcadores tridimensionais reproduzíveis, quantificar a incerteza e oferecer suporte quantitativo à avaliação individualizada da resposta terapêutica.

6.2 Objetivos específicos

1. estruturar uma base de dados longitudinal e anonimizada de PCCT oncológico;
2. criar controle de qualidade automático para dados DICOM espectrais, metadados e calibração;
3. criar modelos de segmentação de órgãos e lesões para os três demonstradores;
4. criar registro rígido e deformável entre exames e entre datas;
5. automatizar a quantificação espectral (mapas de iodo, VNC, VMI) e as correções necessárias;
6. implementar a extração reproduzível de biomarcadores por lesão, por órgão e por paciente;
7. implementar e comparar estratégias de radiômica espectral com análise de estabilidade;
8. estudar IA para redução de dose com preservação do biomarcador;
9. estudar IA para redução de volume de contraste iodado;
10. criar modelos pré-tratamento de previsão de resposta;
11. criar modelos longitudinais adaptativos entre ciclos;
12. estimar e propagar incertezas ao longo da cadeia;
13. criar interface clínica de revisão e relatório;
14. validar o sistema retrospectivamente e, posteriormente, em modo prospectivo silencioso;
15. elaborar rota de transferência tecnológica, propriedade intelectual e evolução regulatória.

7 Casos clínicos demonstradores e estratégia de expansão

7.1 Demonstradores iniciais

Recomenda-se iniciar o projeto com três frentes oncológicas complementares, que compartilham o mesmo núcleo tecnológico e exploram capacidades distintas do PCCT:

Demonstrador 1 – Câncer de pulmão. Detecção, volumetria e caracterização de nódulos pulmonares em protocolos de ultra-baixa dose, com resolução espacial submilimétrica. A literatura recente demonstra ganho de acurácia volumétrica de nódulos com PCCT em regime de rastreamento [6], criando base natural para um demonstrador com forte apelo de saúde populacional.

Demonstrador 2 – Metástases hepáticas de câncer colorretal. Detecção e acompanhamento de lesões hepáticas com reconstruções espectrais otimizadas e mapas de iodo como biomarcador de perfusão tumoral e de resposta a tratamento sistêmico [7, 8]. É o caso que mais utiliza a espectralidade nativa e o elo direto com decisões de oncologia clínica.

Demonstrador 3 – Massas renais. Caracterização não invasiva de massas renais por decomposição de materiais e quantificação de realce, com potencial de reduzir exames adicionais e biópsias. Estudo prospectivo recente comparou PCCT com ressonância magnética nessa tarefa com resultados promissores [9]. É o caso de menor volume, adequado para avaliar a generalização do pipeline.

Em termos simples. Os três demonstradores foram escolhidos como um “teste triplo” da mesma plataforma: o pulmão força o limite de dose e resolução; o fígado força o limite da quantificação espectral; o rim força a capacidade de caracterizar tecido. Se o núcleo funcionar nos três, a generalização para outros sítios tumorais se torna uma extensão natural.

7.2 Expansão planejada

Após validação do núcleo tecnológico, a arquitetura poderá ser estendida para:

- outros sítios tumorais (pâncreas, cabeça e pescoço, linfoma);
- rastreamento oportunista quantitativo (escore de cálcio coronário e densidade óssea em exames oncológicos de rotina);
- integração com dados de anatomia patológica e genômica;
- protocolos multicêntricos e diferentes gerações de equipamentos.

O software será, portanto, **órgão-configurável**: estruturas de interesse, fases de contraste, reconstruções espectrais, modelos de segmentação e regras de biomarcador serão isolados em módulos configuráveis.

8 Arquitetura geral da solução

A Figura 1 apresenta a arquitetura conceitual.

8.1 Princípios arquiteturais

- **modularidade:** cada componente deve poder evoluir independentemente;
- **rastreabilidade:** todo biomarcador deve ser ligado às imagens, aos parâmetros e à versão de algoritmo utilizados;
- **reprodutibilidade:** o mesmo estudo deve produzir o mesmo resultado sob a mesma configuração;
- **human-in-the-loop:** o especialista pode revisar, corrigir e aprovar segmentações e resultados;
- **interoperabilidade:** DICOM/DICOM-SEG/DICOM-SR quando aplicável, DICOMweb e interfaces compatíveis com sistemas clínicos;
- **separação entre pesquisa e uso clínico:** modelos em fase de pesquisa devem operar inicialmente sem modificar condutas.

9 Metodologia técnica detalhada

9.1 Etapa 1 – Ingestão, organização e governança dos dados

A plataforma deverá receber, no mínimo:




Figura 1: Arquitetura conceitual da plataforma AI-Photon.

- séries espectrais de PCCT (VMI em múltiplas energias, mapas de iodo, VNC e, quando disponíveis para pesquisa, dados por bin de energia);
- séries convencionais associadas (fases de contraste, reconstruções de referência);
- parâmetros de aquisição e reconstrução (kV, IQ level, kernel, espessura);
- informações de calibração e da versão de software do equipamento;
- dados demográficos, função renal e exames laboratoriais selecionados;
- marcadores tumorais pertinentes a cada demonstrador (por exemplo, CEA no colorretal);
- esquema terapêutico, datas de ciclos e histórico de tratamentos;
- avaliação de resposta clínica e por critérios de imagem, quando disponível.

Os dados serão organizados em uma estrutura longitudinal:

$$\mathcal{P}_i = \{X_i^{\text{base}}, X_{i,1}^{\text{seg}}, X_{i,2}^{\text{seg}}, \dots, C_i, T_i\}, \quad (4)$$

em que $\mathcal{P}_i$ representa o paciente i , X^{base} o exame basal, X^{seg} os exames de seguimento, C_i os dados clínicos e T_i as informações terapêuticas.

Em termos simples. Antes de treinar qualquer IA, é preciso construir uma base em que os exames corretos estejam ligados ao paciente correto, à data correta, à fase de contraste correta e ao ciclo de tratamento correto. Em quantificação espectral, metadados errados podem ser tão prejudiciais quanto imagens ruins.

9.2 Etapa 2 – Controle de qualidade automático

Será criado um módulo de *quality assurance* (QA) capaz de detectar:

- ausência de séries espectrais esperadas;
- inconsistências de fase de contraste ou de horário de injeção;
- voxel spacing, matriz ou kernel inesperados;
- alteração de protocolo entre exames do mesmo paciente;
- incompatibilidade entre cabeçalhos DICOM;
- valores anômalos de intensidade ou de concentração de iodo;
- possível movimento excessivo;
- falhas de registro;
- distribuição fora do domínio de treinamento da IA.

Cada estudo receberá um *QA score* e alertas antes de prosseguir para as etapas de quantificação.

9.3 Etapa 3 – Segmentação automática

A segmentação deverá identificar estruturas relevantes para cada demonstrador: pulmões, lobos e nódulos; fígado, segmentos hepáticos e lesões metastáticas; rins, córtex, medula e massas renais; além de estruturas de referência (aorta, músculo, baço) para normalização de realce. Serão comparadas estratégias como:

- U-Net/3D U-Net;
- nnU-Net como baseline forte e autoconfigurável;
- arquiteturas híbridas CNN–Transformer;
- modelos fundacionais de segmentação médica, quando adequados;
- aprendizado semissupervisionado para aproveitar dados não rotulados;
- uso das múltiplas reconstruções espectrais como canais de entrada.

A validação utilizará Dice, Jaccard, distância de Hausdorff 95% (HD95), distância média de superfície e, principalmente, **impacto da segmentação sobre o biomarcador**. Uma pequena diferença geométrica pode ser irrelevante visualmente e importante quantitativamente, ou vice-versa.

9.4 Etapa 4 – Registro multimodal e longitudinal

O registro alinhará exames adquiridos em diferentes datas e fases. Serão considerados registro rígido, afim, deformável baseado em intensidade, deformável baseado em aprendizado e restrições anatômicas para evitar deformações não fisiológicas. Para uma transformação deformável ϕ , deseja-se aproximadamente:

$$I_{t_2}(x) \approx I_{t_1}(\phi(x)). \quad (5)$$

Além de métricas de similaridade de imagem, serão avaliados landmarks, sobreposição de estruturas, consistência do Jacobiano e estabilidade da quantificação. O registro longitudinal é o que permite acompanhar cada lesão individualmente ao longo dos ciclos, inclusive as que regredem ou surgem.

9.5 Etapa 5 – Ultra-baixa dose com preservação quantitativa

Esse subprojeto estuda a possibilidade de adquirir com menos dose, ou de recuperar exames ruidosos, sem perder a utilidade quantitativa. Se $\mathbf{y}$ representa as contagens medidas por bin de energia e $\mathbf{x}$ a distribuição espacial dos coeficientes de materiais, o problema pode ser expresso genericamente por:

$$\mathbf{y} \sim \text{Poisson}(\mathbf{Ax} + \mathbf{r}), \quad (6)$$

onde $\mathbf{A}$ representa o modelo do sistema e $\mathbf{r}$ termos como espalhamento e *background*. A estratégia do projeto será priorizar métodos **physics-informed** ou **model-based deep learning**, em que a consistência com os dados medidos é explicitamente preservada. Serão comparados:

- reconstruções e denoising de referência do próprio equipamento;
- denoising pós-reconstrução com redes profundas;
- aprendizado autossupervisionado por exame;
- algoritmos desenrolados (*unrolled*);
- regularização aprendida com termo explícito de consistência física;
- simulação de dose reduzida a partir de exames de dose plena para treinamento pareado.

Resultados recentes demonstram a viabilidade de reduzir dose em PCCT de corpo inteiro com denoising por aprendizado profundo [10], reforçando esse eixo. **Critério fundamental:** a comparação deverá incluir erro em concentração de iodo, erro em números de TC nas VMI, detectabilidade de lesões pequenas e erro nos biomarcadores finais, não apenas PSNR, SSIM ou avaliação visual.

9.6 Etapa 6 – Quantificação espectral e calibração

Após reconstrução e decomposição, o objetivo é obter estimativas confiáveis de concentração de iodo:

$$c_I(x, y, z, t) \quad [\text{mg/mL}] \quad (7)$$

e de carga funcional por estrutura:

$$Q_\Omega(t) = \int_\Omega c_I(x, y, z, t) dV. \quad (8)$$

O módulo deverá documentar e controlar fatores como: exatidão da decomposição de materiais, normalização pelo realce aórtico e pelo débito de contraste, fase de aquisição, efeito de volume parcial, movimento, kernel e nível de energia das VMI, além de sincronização temporal entre injeção e aquisição. A exatidão será ancorada em **phantoms com insertos de concentração conhecida**, com verificação periódica e rastreável [8, 3].

9.7 Etapa 7 – Radiômica espectral e harmonização

Para cada lesão e órgão, serão extraídos atributos de intensidade, forma e textura sobre as reconstruções convencionais e espectrais (VMI em múltiplas energias, mapas de iodo). A literatura mostra que a estabilidade radiômica em PCCT depende de dose, energia virtual e parâmetros de reconstrução [11], portanto o projeto tratará a harmonização como problema científico próprio:

- análise de repetibilidade e reprodutibilidade (ICC) por atributo;
- seleção de atributos estáveis entre protocolos e energias;
- métodos de harmonização estatística entre lotes;

- padronização compatível com IBSI;
- avaliação do ganho real dos atributos espectrais frente aos convencionais.

9.8 Etapa 8 – Redução de contraste iodado

A alta razão contraste-ruído do PCCT em baixas energias virtuais cria espaço para protocolos com menos contraste iodado, tema já demonstrado em estudos de viabilidade [12]. O projeto avaliará protocolos de volume reduzido com a pergunta científica formulada em termos de biomarcador:

$$\left\{c_I^{\text{padrão}}\right\} \longrightarrow \left\{c_I^{\text{reduzido}}\right\} : \quad \text{o erro em } Q_{\Omega} \text{ permanece clinicamente aceitável?} \quad (9)$$

Os benefícios potenciais incluem menor risco renal, menor custo por exame e maior elegibilidade de pacientes fragilizados, população frequente em oncologia.

9.9 Etapa 9 – Motor de biomarcadores

Serão implementados níveis complementares:

Nível A – Biomarcadores por lesão e por órgão. Volume, diâmetros, concentração média e total de iodo, realce normalizado. Adequados para comparação clínica, validação e resultados agregados.

Nível B – Biomarcadores voxelizados. Mapas $c_I(x, y, z)$ e mapas de mudança entre datas, permitindo avaliar heterogeneidade intratumoral e resposta espacialmente heterogênea.

Nível C – Referência física. Phantoms espectrais e protocolos de referência serão utilizados como ancoragem metrológica em subconjuntos selecionados, para avaliar erros dos métodos mais rápidos.

O projeto deverá registrar a origem de cada resultado, por exemplo:

```
biomarker_method = iodine_map_v2.1
segmentation_model = liver_seg_v1.4
calibration_protocol = pcct_siteA_2026
```

Essa rastreabilidade é essencial para pesquisa reprodutível e futura industrialização.

9.10 Etapa 10 – AI Predictive Response

Esta é uma das principais inovações propostas. Antes do início do tratamento, deseja-se aprender uma função:

$$f : \left(X_{\text{PCCT}}^{\text{base}}, C, T\right) \rightarrow \hat{R}, \quad (10)$$

em que $\hat{R}$ representa a resposta esperada (variação de carga tumoral, categoria de resposta ou tempo até progressão, conforme o endpoint definido com a equipe clínica). As entradas poderão incluir:

- volume tumoral total e número de lesões;
- concentração e distribuição de iodo nas lesões;
- textura e radiômica espectral;
- volumes e características anatômicas;

- função renal e hepática;
- marcadores laboratoriais selecionados;
- esquema terapêutico planejado;
- características do histórico terapêutico.

Serão comparados modelos simples e complexos: regressão regularizada, Random Forest/Extra Trees, Gradient Boosting, XGBoost/LightGBM quando permitido pelo ambiente, redes multi-modais 3D combinadas a variáveis tabulares e modelos de sobrevivência em fases posteriores. A preferência metodológica será por **baselines transparentes antes de modelos grandes**.

9.11 Etapa 11 – AI Longitudinal Tracking

Após o primeiro exame de reavaliação, o sistema passa a dispor de informação individual observada:

$$TB^{(1)}, \quad Q_\ell^{(1)}, \quad R^{(1)}, \quad (11)$$

onde $R^{(1)}$ pode representar variáveis de resposta do primeiro intervalo. O modelo para o intervalo seguinte pode ser escrito como:

$$\hat{R}^{(2)} = g\left(X^{\text{base}}, C, TB^{(1)}, Q^{(1)}, R^{(1)}\right). \quad (12)$$

Esse mecanismo permite estudar uma transição de:

modelo populacional $\rightarrow$ modelo informado pelo próprio paciente.

Ponto de atenção. Na fase de pesquisa, a saída preditiva e longitudinal será uma estimativa e não uma recomendação automática de conduta. Qualquer modificação terapêutica deverá permanecer sob responsabilidade da equipe clínica e, em validação prospectiva inicial, o algoritmo deverá operar em *silent mode*.

9.12 Etapa 12 – Incerteza e confiança

Toda medida e toda previsão deverão ser acompanhadas por uma medida de confiança. Em vez de exibir apenas:

Carga de iodo tumoral = 142 mg,

a plataforma deverá buscar apresentar:

Carga de iodo tumoral = 142 mg; intervalo = [128; 156] mg.

Serão estudados bootstrap, ensembles, regressão quantílica, métodos Bayesianos, conformal prediction e propagação de incerteza da segmentação e da quantificação. A análise deverá separar, sempre que possível: incerteza de aquisição, de calibração, de segmentação, de registro, de decomposição espectral, do modelo preditivo e da harmonização radiômica.

10 Plataforma de software

10.1 Camadas

A implementação será dividida em cinco camadas:

1. **Data Layer:** DICOM espectral, banco de metadados, versionamento e anonimização;

2. **Imaging Layer:** denoising, registro, segmentação e quantificação espectral;
3. **Biomarker Layer:** radiômica, harmonização, agregação por lesão, órgão e paciente;
4. **AI Layer:** modelos preditivos, longitudinais e incerteza;
5. **Application Layer:** interface, revisão humana, relatórios e integração.

10.2 Stack tecnológico sugerido

A escolha final dependerá dos requisitos de integração da Siemens Healthineers, mas um stack de pesquisa pode incluir:

- Python como linguagem principal;
- PyTorch/MONAI para IA em imagem médica;
- SimpleITK/ITK para processamento e registro;
- pydicom/highdicom para DICOM;
- PyRadiomics compatível com IBSI para radiômica;
- NiBabel/NIfTI no ambiente de pesquisa;
- PostgreSQL para metadados estruturados;
- armazenamento de objetos para imagens;
- FastAPI para serviços;
- containers OCI/Docker para reprodutibilidade;
- MLflow ou equivalente para rastreamento de experimentos;
- Git + CI/CD;
- frontend web com visualizador DICOM compatível com OHIF ou tecnologia equivalente;
- GPU para treinamento e CPU/GPU para inferência, conforme cada módulo.

10.3 MLOps e rastreabilidade

Cada modelo deverá ter um *model card* contendo: conjunto de treinamento; critérios de inclusão/exclusão; equipamento/protocolo conhecido; versão de preprocessing; métricas de validação; limitações; população-alvo; condições de uso; versão de código e pesos; e data de aprovação para determinada fase do estudo.

11 Base de dados e estratégia amostral

11.1 Acesso ao equipamento como parte da estratégia

Diferentemente de tecnologias já disseminadas, o PCCT possui base instalada ainda em expansão no Brasil. Por isso, a estratégia de dados do projeto será construída em três trilhas complementares:

1. **Dados retrospectivos de parceiros que já operam PCCT**, no Brasil e, quando viável, no exterior, mediante acordos de pesquisa;
2. **Dados públicos e simulação espectral** (phantoms computacionais, simuladores de aquisição e degradação realista de dose) para as etapas de engenharia e de prova de conceito;

3. **Aquisição prospectiva local**, à medida que o acesso a equipamento da classe NAEOTOM se concretize com a Siemens e o parceiro clínico, o que constitui, em si, parte da negociação desta proposta.

Ponto de atenção. A validação em população latino-americana é um ativo estratégico para a Siemens: a maior parte da evidência de PCCT publicada vem da Europa e dos Estados Unidos. Uma base regional bem governada torna o projeto complementar, e não redundante, frente à pesquisa internacional existente.

11.2 Fases da base

Fase A – Piloto técnico: conjunto pequeno, cuidadosamente curado, para validar pipeline, DICOM espectral, segmentação, registro e quantificação;

Fase B – Retrospectiva ampliada: coorte utilizada para criação de modelos e validação cruzada;

Fase C – Validação temporal: pacientes de período posterior ao treinamento;

Fase D – Validação externa/multicêntrica: quando houver parceiro adicional;

Fase E – Prospectiva silenciosa: o sistema gera medidas e previsões em novos pacientes sem interferir na decisão clínica.

11.3 Faixas amostrais para planejamento

Sem conhecer ainda a disponibilidade real de dados, recomenda-se trabalhar com faixas e realizar cálculo amostral específico para cada endpoint.

Tabela 1: Faixas iniciais de planejamento, a serem revistas após o inventário de dados.

Fase	Faixa sugerida / finalidade
Piloto técnico	20–30 exames para fechar o pipeline ponta a ponta
Retrospectiva inicial	80–150 pacientes por demonstrador, se disponíveis, para modelos e análise de viabilidade
Expansão	300–600 pacientes ou mais, idealmente multicêntricos, para modelos multimodais de maior capacidade
Prospectiva silenciosa	40–80 pacientes como estudo inicial de generalização operacional

Ponto de atenção. Esses números são metas de planejamento, não um cálculo amostral definitivo. O tamanho adequado depende do endpoint, variância observada, número de lesões por paciente, correlação intraindivíduo e objetivo de não-inferioridade ou equivalência. O plano estatístico será congelado antes da validação final.

11.4 Regionalidade como questão científica

A criação de uma base no Ceará e no Nordeste brasileiro pode ser tratada como uma contribuição científica e não apenas institucional. Será possível avaliar: *domain shift* entre populações; variações de protocolo; diferenças de reconstrução; transfer learning; domain adaptation; harmonização radiômica; e aprendizado federado em futura expansão multicêntrica.

12 Desenho experimental e validação

12.1 Princípio geral

A validação será construída em cascata. Um módulo só será considerado útil se o seu benefício permanecer visível na variável clinicamente relevante da etapa seguinte.

Imagem → Quantificação espectral → Biomarcador → Predição → Decisão.

12.2 Métricas

Tabela 2: Métricas principais por componente.

Componente	Métricas principais
Segmentação	Dice, Jaccard, HD95, distância média de superfície, erro de volume e erro de concentração de iodo na VOI.
Registro	Target Registration Error, sobreposição de estruturas, consistência de landmarks, Jacobiano e impacto sobre o biomarcador.
Denoising/dose	erro em números de TC nas VMI, erro em concentração de iodo, NPS, detectabilidade de baixo contraste, bias; PSNR/SSIM apenas como métricas auxiliares.
Quantificação	erro absoluto/relativo em mg/mL, calibração em phantom, recovery coefficient, repetibilidade e reprodutibilidade.
Radiômica	ICC, estabilidade entre energias/protocolos, redundância e ganho preditivo incremental.
Predição	AUC ou MAE/RMSE conforme o endpoint, R^2 , calibração, intervalos preditivos, cobertura de conformal prediction, validação por paciente.
Operacional	tempo de processamento, necessidade de edição manual, dose e volume de contraste por exame, taxa de falhas e número de alertas QA.

12.3 Separação correta dos dados

A divisão treinamento/validação/teste deverá ocorrer por **paciente**, e não por lesão ou imagem. Caso existam múltiplas lesões e múltiplos exames de um mesmo paciente, todos devem permanecer no mesmo conjunto durante a validação de generalização. Isso evita *data leakage*, em que o modelo parece generalizar porque recebe no teste informações de um indivíduo que já apareceu no treinamento.

12.4 Validação de modelos com poucas amostras

Serão priorizadas: validação cruzada aninhada; bootstrap; modelos parcimoniosos; seleção de atributos dentro do loop de validação; análise por paciente; validação temporal; e conjunto externo quando disponível.

12.5 Metas técnicas provisórias

As metas abaixo são referências de engenharia e serão refinadas com a equipe clínica e a Siemens Healthineers:

- automatizar a maior parte do processamento com revisão humana orientada por exceção;
- reduzir substancialmente o tempo de processamento por paciente;
- demonstrar pelo menos uma configuração de dose reduzida com preservação quantitativa aceitável;
- demonstrar pelo menos um protocolo de contraste reduzido com erro em biomarcador clinicamente discutível frente ao protocolo de referência;
- produzir previsão de resposta melhor que baselines populacionais;
- produzir intervalos de incerteza calibrados;
- demonstrar generalização temporal e, se possível, externa.

Não se recomenda fixar neste momento um único limite universal de erro, pois a aceitabilidade depende do órgão, da lesão, do método de referência, do protocolo e da finalidade clínica.

13 Work Packages

WP1 – Governança, dados e infraestrutura. Objetivo: estabelecer base de dados, pipeline DICOM espectral, anonimização, controle de qualidade e ambiente reproduzível. **Atividades:** inventário; data dictionary; protocolos; anonimização; armazenamento; QA; MLOps; documentação. **Entregáveis:** **D1.1** Plano de gestão de dados; **D1.2** Data lake anonimizado; **D1.3** Pipeline DICOM; **D1.4** módulo de QA.

WP2 – Segmentação, registro e quantificação espectral. Objetivo: automatizar a preparação anatômica e quantitativa das imagens. **Atividades:** segmentação; registro longitudinal; calibração; quantificação de iodo; análise de volume parcial. **Entregáveis:** **D2.1** modelos de segmentação; **D2.2** motor de registro; **D2.3** pipeline quantitativo espectral validado.

WP3 – Física de imagem e referência metrológica. Objetivo: implementar a referência quantitativa do projeto. **Atividades:** phantoms espectrais; protocolos de calibração; análise de exatidão; propagação de incerteza; benchmark. **Entregáveis:** **D3.1** protocolo de calibração espectral; **D3.2** motor de biomarcadores; **D3.3** protocolo de benchmark.

WP4 – IA para redução de dose e de contraste. Objetivo: diminuir o custo em dose, contraste e tempo da imagem oncológica quantitativa. **Atividades:** simulação de dose reduzida; denoising com preservação quantitativa; protocolos de contraste reduzido; estudo comparativo. **Entregáveis:** **D4.1** protótipo AI Ultra-Low-Dose; **D4.2** protótipo de contraste reduzido; **D4.3** estudo comparativo de dose e contraste.

WP5 – IA preditiva e longitudinal. Objetivo: prever resposta antes do tratamento e atualizar a previsão entre ciclos. **Atividades:** radiômica espectral; harmonização; modelos tabulares; modelos multimodais; previsão de resposta; adaptação longitudinal; incerteza. **Entregáveis:** **D5.1** modelo preditivo; **D5.2** modelo longitudinal; **D5.3** módulo de incerteza.

WP6 – Plataforma, validação e transferência. Objetivo: integrar os módulos e demonstrar operação no fluxo clínico. **Atividades:** backend; frontend; viewer; relatórios; human-in-the-loop; estudo retrospectivo; prospectivo silencioso; propriedade intelectual; documentação de produto. **Entregáveis:** **D6.1** plataforma integrada; **D6.2** relatório de validação; **D6.3** demonstrador clínico; **D6.4** roadmap de produto/IP/regulação.

14 Cronograma sugerido

O cronograma de 30 meses prioriza a entrega antecipada de um pipeline mínimo e adiciona progressivamente as capacidades de IA.

Tabela 3: Cronograma sugerido em 30 meses.

Atividade	Meses	Marco
Governança, CEP, LGPD e inventário	1–4	Base legal/técnica e dicionário de dados
Infraestrutura e pipeline DICOM espectral	1–6	Ingestão e anonimização operacionais
Segmentação e registro	4–12	Primeiros modelos validados retrospectivamente
Quantificação espectral e calibração	5–14	Referência quantitativa do projeto
IA Ultra-Low-Dose	8–18	Comparação dose plena vs. reduzida
Contraste reduzido	10–20	Protótipo de protocolo com menos iodo
AI Predictive Response	10–22	Modelo pré-tratamento
AI Longitudinal Tracking	15–24	Modelo entre ciclos
Incerteza e OOD	14–24	Intervalos de confiança e alertas
Integração da plataforma	12–26	MVP integrado
Validação temporal/externa	20–28	Evidência de generalização
Prospectivo silencioso	24–29	Avaliação em novos pacientes sem interferência clínica
Roadmap de produto, IP e relatório final	27–30	Pacote de transferência tecnológica

15 MVP e evolução tecnológica

15.1 MVP 1 – Quantificação espectral automatizada reprodutível

Entrada: PCCT espectral + dados clínicos. Saída: segmentações, mapas de iodo, biomarcadores por lesão e por paciente, mapas selecionados e relatório.

15.2 MVP 2 – Imagem quantitativa com menor custo de aquisição

Inclui: AI Ultra-Low-Dose + protocolo de contraste reduzido, sempre com validação por erro em biomarcador.

15.3 MVP 3 – Predição pré-tratamento

Entrada: PCCT basal + dados clínicos + esquema terapêutico. Saída: estimativa de resposta esperada e intervalo de incerteza.

15.4 MVP 4 – Acompanhamento longitudinal adaptativo

Entrada: dados basais + resultados dos exames de reavaliação. Saída: estimativa atualizada para o intervalo subsequente e alerta de trajetória.

15.5 Visão de produto

A evolução poderá seguir uma escala de maturidade:

algoritmos experimentais → pipeline reproduzível → MVP clínico → validação externa → industrialização.

16 Equipe e responsabilidades

A equipe deve ser obrigatoriamente multidisciplinar.

Tabela 4: Perfis e responsabilidades.

Perfil	Responsabilidade
Coordenador de P&D	governança científica, integração entre IA, software e parceiro clínico, metas, publicações e transferência.
Coordenador técnico de IA	arquitetura de modelos, experimentos, MLOps, revisão de código e validação.
Radiologista	definição clínica, seleção de casos, revisão de imagens, relevância dos endpoints e segurança.
Oncologista clínico	endpoints de resposta, esquemas terapêuticos, interpretação clínica dos biomarcadores.
Físico médico / especialista em física de imagem	calibração espectral, phantoms, quantificação, dose e benchmark.
Pesquisador de visão computacional	segmentação, registro, denoising e modelos 3D.
Pesquisador de ML multimodal	radiômica, dados tabulares, predição, adaptação e incerteza.
Engenheiro de software	backend, APIs, DICOM, banco, integração e interface.
Engenheiro de dados/MLOps	pipeline de dados, versionamento, rastreamento, CI/CD e monitoramento.
Alunos de pós-graduação	subproblemas científicos e validações específicas.
Aluno de graduação	curadoria, testes, automação e ferramentas auxiliares sob supervisão.
Especialista regulatório/qualidade	rota SaMD, documentação, gestão de risco e preparação para industrialização.

16.1 Divisão institucional sugerida

Grupo de Saúde Digital – Universidade Estadual do Ceará (UECE): IA, visão computacional e aprendizado multimodal; otimização e modelagem; construção de software; MLOps e avaliação científica; formação de recursos humanos.

Parceiro clínico de diagnóstico por imagem / Omnimagem: acesso e curadoria dos exames; especialistas; validação clínica; protocolos de aquisição; estudos retrospectivos e prospectivos.

Siemens Healthineers: expertise de equipamentos e do dado espectral; requisitos industriais; orientação de integração; priorização de casos de uso; avaliação de escalabilidade; acesso a equipamento e ferramentas de pesquisa; conexão com roadmap de produto e ecossistema syngo, quando aplicável.

17 Ética, LGPD, segurança e regulação

17.1 Ética em pesquisa

O uso de dados clínicos deverá ser submetido ao sistema CEP/CONEP quando aplicável, com protocolo de pesquisa específico, critérios de acesso e responsabilidades claramente definidos.

17.2 Proteção de dados

Dados de saúde são dados pessoais sensíveis. A governança será baseada em: minimização de dados; anonimização ou pseudonimização conforme a fase; controle de acesso por perfil; logs de acesso; criptografia em trânsito e em repouso; segregação entre identificadores e dados de pesquisa; política de retenção; e análise contínua de risco de reidentificação. A LGPD e documentos técnicos da ANPD serão considerados na definição do tratamento de dados para pesquisa [13, 14].

17.3 Software como dispositivo médico

Caso o protótipo evolua para finalidade médica de apoio diagnóstico/terapêutico, deverá ser realizado enquadramento regulatório como Software as a Medical Device (SaMD), considerando a regulamentação vigente da Anvisa, incluindo a RDC 657/2022 e eventuais revisões [15]. A documentação de P&D será organizada desde o início para facilitar futura industrialização: requisitos; arquitetura; versionamento; testes; gestão de risco; evidência de desempenho; rastreabilidade; cibersegurança; e registro de mudanças de modelo.

Ponto de atenção. A RDC 657/2022 está incluída na agenda regulatória brasileira para possível revisão. Portanto, o projeto deverá trabalhar com uma *regulatory watch* e não presumir que a redação atual permanecerá inalterada até a fase de produto.

18 Riscos e estratégias de mitigação

19 Indicadores de sucesso

Os KPIs serão divididos em cinco dimensões.

19.1 Científicos

Artigos submetidos a periódicos de radiologia, física médica e IA em saúde; dissertações/teses; participação em congressos; novos métodos validados.

19.2 Tecnológicos

Pipeline automatizado ponta a ponta; percentual de exames processados sem falha; tempo médio de processamento; redução de edição manual; desempenho quantitativo do AI Ultra-Low-Dose; desempenho do protocolo de contraste reduzido; desempenho preditivo e calibração.

19.3 Clínico-operacionais

Redução potencial de dose por exame; redução potencial de volume de contraste; concordância com referência quantitativa; taxa de casos que necessitam intervenção manual; avaliação de usabilidade por especialistas.

Tabela 5: Riscos e estratégias de mitigação.

Risco	Impacto	Mitigação
Acesso limitado a equipamento PCCT	atraso na base prospectiva	trilhas paralelas: dados retrospectivos de parceiros, dados públicos e simulação espectral; acesso a equipamento como pauta da parceria.
Poucos pacientes	overfitting e baixa generalização	modelos simples, transfer learning, autossupervisão, validação temporal, expansão multicêntrica.
Dados incompletos	impossibilidade de calcular referência	data dictionary, QA, critérios de inclusão e análise de missingness.
Heterogeneidade de protocolos	domain shift	padronização, harmonização, metadados de aquisição e domain adaptation.
Segmentação imprecisa	erro de biomarcador	human-in-the-loop, análise de sensibilidade e QA automático.
Registro deformável inadequado	erro longitudinal	landmarks, restrições anatômicas, alarmes de deformação e revisão visual.
IA melhora imagem, mas altera quantificação	erro silencioso de biomarcador	métricas quantitativas obrigatórias e estudos com phantom.
Modelo preditivo excessivamente confiante	risco clínico	calibração, conformal prediction, OOD detection e revisão humana.
Dificuldade de integração	atraso de produto	arquitetura modular, APIs e padrões DICOM desde o início.
Mudança regulatória	retrabalho	regulatory watch e documentação compatível com qualidade desde P&D.

19.4 Inovação

Depósitos de software/patentes quando cabíveis; componentes licenciáveis; demonstração integrada; potencial de incorporação ao portfólio industrial.

19.5 Formação

Pesquisadores treinados em imagem espectral quantitativa e IA; formação de alunos em imagem médica quantitativa; fortalecimento de competência regional em PCCT.

20 Entregáveis consolidados

Ao final do projeto, espera-se possuir:

1. base de dados de PCCT oncológico estruturada e governada;
2. protocolo de calibração espectral e QA computacional;
3. modelos de segmentação para os três demonstradores;
4. módulo de registro longitudinal;
5. pipeline de quantificação espectral;
6. motor de biomarcadores por lesão, órgão e paciente;
7. módulo de radiômica espectral harmonizada;
8. benchmark metrológico com phantoms em casos selecionados;
9. protótipo AI Ultra-Low-Dose;
10. protótipo de protocolo de contraste reduzido;
11. modelo AI Predictive Response;
12. modelo AI Longitudinal Tracking;
13. módulo de incerteza e OOD;
14. interface clínica integrada;
15. estudo retrospectivo;
16. estudo prospectivo silencioso, se autorizado;
17. documentação técnica;
18. publicações e formação de recursos humanos;
19. relatório de propriedade intelectual;
20. roadmap de industrialização e regulação.

21 Estrutura de orçamento

Os valores deverão ser construídos em conjunto com a Siemens Healthineers, mas a proposta deve prever as seguintes categorias: bolsas para coordenação e pesquisadores; bolsas de pós-graduação e graduação; engenheiro de software contratado; horas de especialista clínico/físico quando aplicável; infraestrutura GPU; armazenamento e backup; servidor de integração; licenças eventualmente necessárias; phantom espectral e materiais de calibração; custos de estudo

clínico; missões técnicas e reuniões de integração; publicação e eventos; registro de propriedade intelectual; e serviços regulatórios e de qualidade.

Uma estratégia adequada é dividir o orçamento por WP, permitindo que a Siemens identifique claramente o custo associado a cada capacidade tecnológica.

22 Propriedade intelectual e transferência tecnológica

Antes do início dos trabalhos, recomenda-se um acordo definindo:

- **background IP:** conhecimento e software preexistentes de cada parte;
- **foreground IP:** resultados criados durante o projeto;
- titularidade e licenciamento;
- direitos de uso para pesquisa;
- regras de publicação;
- período de revisão pré-publicação para proteção de IP;
- tratamento de código aberto e dependências;
- governança dos dados clínicos;
- regras para modelos treinados com dados do parceiro.

O desenho modular facilita separar:

núcleo científico | componentes patenteáveis | software de integração | dados clínicos.

23 Diferenciais da proposta

A proposta se diferencia por oito características:

1. **não se limita à segmentação;**
2. **não se limita ao denoising;**
3. **mede impacto final em biomarcador;**
4. **usa a espectralidade nativa do PCCT como eixo central;**
5. **integra física de imagem e IA;**
6. **prevê resposta antes do tratamento;**
7. **aprende com os ciclos anteriores de cada paciente;**
8. **reporta incerteza e mantém o especialista no circuito.**

Uma formulação curta do diferencial é:

**From Spectral Imaging to Predictive and
Adaptive Quantitative Oncology.**

24 Cenário demonstrativo

Considere um paciente com câncer colorretal metastático que iniciará tratamento sistêmico.

Antes do tratamento

O sistema recebe o PCCT basal, exames laboratoriais e dados clínicos. Segmenta automaticamente fígado e lesões, quantifica os mapas de iodo e calcula:

Carga tumoral hepática: 96 mL em 7 lesões
Carga de iodo tumoral: 142 mg; intervalo = [128; 156] mg
Resposta esperada ao esquema planejado: redução de 30% a 45% na carga de iodo.

Esses números são **estimativas de pesquisa**, apresentadas ao especialista, não uma prescrição.

Após o primeiro intervalo de tratamento

O paciente realiza o PCCT de reavaliação. O sistema registra os exames, acompanha cada lesão individualmente e estima:

Carga tumoral hepática observada: 71 mL
Carga de iodo observada: 97 mg (redução de 32%).

O sistema registra o erro da previsão e sinaliza duas lesões com comportamento discordante da média.

No intervalo seguinte

O modelo utiliza os dados originais mais a trajetória real do primeiro intervalo:

$$\hat{R}^{(2)} = g(\text{PCCT}^{\text{base}}, \text{clínica}, TB^{(1)}, Q^{(1)}). \quad (13)$$

A previsão passa a refletir não somente “pacientes parecidos”, mas também **como aquele paciente específico respondeu ao tratamento**.

Em termos simples. É esse mecanismo que dá sentido ao termo “longitudinal adaptativo”. O sistema começa com conhecimento populacional e, a cada reavaliação, recebe novas evidências sobre o comportamento biológico daquele indivíduo.

25 Perguntas científicas que podem gerar publicações

O projeto pode ser decomposto em linhas publicáveis independentes:

1. segmentação multimodal de órgãos e lesões sobre reconstruções espectrais;
2. registro longitudinal com preservação quantitativa;
3. denoising de PCCT com preservação de biomarcador espectral;
4. impacto da IA de reconstrução sobre a concentração de iodo;
5. estabilidade e harmonização de radiômica espectral;
6. quantificação de iodo como biomarcador de resposta em metástases hepáticas;
7. volumetria de nódulos pulmonares em ultra-baixa dose;
8. caracterização de massas renais por decomposição de materiais;
9. predição de resposta com dados multimodais basais;
10. modelos longitudinais entre ciclos;

11. conformal prediction em biomarcadores de imagem;
12. domain adaptation Brasil vs. coortes externas.

Essa divisão é importante porque garante valor científico mesmo que um módulo de maior risco, como a predição pré-tratamento, não alcance imediatamente desempenho suficiente para evolução clínica.

26 Plano de decisão Go/No-Go

Para um projeto industrial, recomenda-se adotar gates.

Gate 1 – Mês 6

Pergunta: os dados e a infraestrutura são suficientes?

Go se houver: pipeline DICOM espectral funcional, base piloto, calibração documentada e viabilidade de ligar imagens aos ciclos de tratamento.

Gate 2 – Mês 14

Pergunta: existe referência quantitativa reprodutível?

Go se: segmentação, quantificação de iodo e biomarcadores forem reprodutíveis em coorte retrospectiva.

Gate 3 – Mês 20

Pergunta: reduzir dose e contraste é tecnicamente útil?

Go se: pelo menos uma estratégia reduzida preservar o biomarcador dentro de faixa aceitável definida com os especialistas.

Gate 4 – Mês 24

Pergunta: a previsão agrega valor sobre baselines?

Go se: modelo preditivo superar referências populacionais e apresentar calibração adequada.

Gate 5 – Mês 30

Pergunta: há evidência suficiente para industrialização?

Decisão conjunta: continuar P&D, ampliar multicentro, preparar produto ou manter como ferramenta de pesquisa.

27 Resultados esperados e impacto

27.1 Para pacientes

Potencial de: menos radiação e menos contraste por exame; avaliação de resposta mais sensível que critérios puramente dimensionais; menos procedimentos invasivos de caracterização; acompanhamento quantitativo longitudinal.

27.2 Para serviços de radiologia e oncologia

Potencial de: menor trabalho manual; maior padronização; laudos quantitativos comparáveis entre datas; maior throughput; geração automatizada de relatórios quantitativos.

27.3 Para a Siemens Healthineers

Potencial de: novos módulos de IA oncológica sobre a plataforma NAEOTOM; evidência de valor clínico do dado espectral em novos casos de uso; diferenciação tecnológica; validação em uma população latino-americana; ativos de IP e publicações; aproximação com centros clínicos e formação de especialistas na tecnologia.

27.4 Para o Ceará e para o grupo proponente

Potencial de: criar competência regional em IA para imagem espectral; formar recursos humanos em área de alta complexidade; estabelecer base para novos projetos em TC quantitativa; atrair cooperações e ensaios; consolidar um núcleo de pesquisa em oncologia computacional por imagem.

28 Mensagem recomendada para apresentação à empresa

A proposta pode ser resumida para uma reunião executiva da seguinte forma:

A TC oncológica atual responde principalmente à pergunta: “*como a doença aparece?*”

O AI-Photon propõe avançar para três perguntas:

1. **Quanta doença existe, medida em números reprodutíveis?**
2. **Como este paciente provavelmente responderá ao tratamento?**
3. **O que podemos aprender com cada reavaliação para tornar a próxima estimativa mais individualizada?**

A tecnologia proposta une o dado espectral do PCCT, física de imagem e IA em um ciclo contínuo de quantificação, previsão, medição e adaptação.

29 Próximos passos recomendados

Antes da submissão final à Siemens Healthineers, recomenda-se realizar uma reunião técnica curta com cinco decisões objetivas:

1. confirmar os demonstradores oncológicos prioritários;
2. inventariar quantidade e tipos de dados de PCCT acessíveis (parceiros, acordos, simulação);
3. identificar equipamentos e protocolos de aquisição envolvidos;
4. definir quais módulos são prioritários para a Siemens: Ultra-Low-Dose, contraste reduzido, Predictive Response ou Longitudinal Tracking;
5. fechar escopo, duração, equipe, orçamento e propriedade intelectual.

Com essas respostas, esta proposta pode ser convertida em uma versão contratual com metas quantitativas, TRLs, orçamento detalhado e responsabilidades institucionais.

Referências

- [1] SIEMENS HEALTHINEERS. *Siemens Healthineers Receives FDA Clearance for Naeotom Alpha Class of Photon-Counting Computed Tomography Scanners*. Disponível em: <https://www.siemens-healthineers.com/en-us/press-room/press-releases/naeotom-family-fda-clearance>. Acesso em: 31 ago. 2026.

- [2] SIEMENS HEALTHINEERS BRASIL. *Tomografia computadorizada NAEOTOM Alpha com contagem de fótons*. Disponível em: <https://www.siemens-healthineers.com/br/computed-tomography/naeotom/naeotom-alpha>. Acesso em: 31 ago. 2026.
- [3] SCHWARTZ, F. R.; SODICKSON, A. D.; PICKHARDT, P. J.; SAHANI, D. V.; LEV, M. H.; GUPTA, R. Photon-Counting CT: Technology, Current and Potential Future Clinical Applications, and Overview of Approved Systems and Those in Various Stages of Research and Development. *Radiology*, v. 314, n. 3, 2025. DOI: <https://doi.org/10.1148/radiol.240662>.
- [4] BRUNO, E.; PALMISANO, A.; CAMISASSA, E.; VIGNALE, D.; TACCHETTI, C.; ESPOSITO, A. et al. Photon-counting detector CT in oncology: a new era of cancer imaging. *Insights into Imaging*, v. 17, art. 15, 2026. DOI: <https://doi.org/10.1186/s13244-025-02176-2>.
- [5] Applications of photon-counting CT in oncologic imaging: a systematic review. *World Journal of Radiology*, v. 17, n. 8, 2025. Disponível em: <https://www.wjgnet.com/1949-8470/full/v17/i8/107732.htm>.
- [6] Improvement of Lung Nodule Volumetric Accuracy with Photon-counting Computed Tomography over Energy-integrating Computed Tomography in Low-dose Screening. *Investigative Radiology*, 2025. DOI: <https://doi.org/10.1097/RLI.0000000000001299>.
- [7] Analysis of colorectal liver metastases in photon-counting detector CT: optimizing imaging through spectral reconstruction. *Cancer Imaging*, v. 26, 2026. DOI: <https://doi.org/10.1186/s40644-026-01044-6>.
- [8] Liver Iodine Quantification with Photon-Counting Detector CT: Accuracy in an Abdominal Phantom and Feasibility in Patients. *Academic Radiology*, 2022. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/35644755/>.
- [9] HOMAYOUNIEH, F. et al. A Prospective Study of the Diagnostic Performance of Photon-Counting CT Compared with MRI in the Characterization of Renal Masses. *Investigative Radiology*, 2024. DOI: <https://doi.org/10.1097/RLI.0000000000001087>.
- [10] Evaluation of a Deep Learning Denoising Algorithm for Dose Reduction in Whole-Body Photon-Counting CT Imaging: A Cadaveric Study. *Academic Radiology*, 2025. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/39818525/>.
- [11] Robustness of radiomics within photon-counting detector CT: impact of acquisition and reconstruction factors. *European Radiology*, 2025. DOI: <https://doi.org/10.1007/s00330-025-11374-x>.
- [12] Potential of photon-counting detector CT technology for contrast medium reduction in portal venous phase thoracoabdominal CT. *European Radiology*, 2025. DOI: <https://doi.org/10.1007/s00330-025-11409-3>.
- [13] BRASIL. Lei n. 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD), texto compilado. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709compilado.htm. Acesso em: 31 ago. 2026.
- [14] AUTORIDADE NACIONAL DE PROTEÇÃO DE DADOS (ANPD). *A LGPD e o tratamento de dados pessoais para fins acadêmicos e para a realização de estudos por órgão de pesquisa*. Documento técnico orientativo.

- [15] AGÊNCIA NACIONAL DE VIGILÂNCIA SANITÁRIA (ANVISA). RDC n. 657, de 24 de março de 2022. Dispõe sobre a regularização de Software como Dispositivo Médico (Software as a Medical Device – SaMD). Disponível em: <https://www.gov.br/anvisa/pt-br/assuntos/noticias-anvisa/2022/software-como-dispositivo-medico-perguntas-e-respostas>. Acesso em: 31 ago. 2026.

A Checklist para fechar a versão a ser enviada à Siemens

Antes do envio, preencher:

- ☐ nome oficial do grupo/laboratório;
- ☐ nome do responsável na Siemens Healthineers;
- ☐ instituição clínica participante;
- ☐ equipamento(s) PCCT acessíveis e localização;
- ☐ demonstradores oncológicos confirmados;
- ☐ número aproximado de pacientes retrospectivos por demonstrador;
- ☐ existência de exames longitudinais (basal + reavaliações);
- ☐ disponibilidade de séries espectrais arquivadas (VMI, iodo, VNC);
- ☐ método de quantificação atualmente empregado;
- ☐ especialistas de radiologia, oncologia e física médica;
- ☐ duração contratual;
- ☐ orçamento;
- ☐ regras de propriedade intelectual;
- ☐ metas quantitativas por WP;
- ☐ entregáveis exigidos pela Siemens;
- ☐ plano de publicação;
- ☐ fluxo de aprovação ética e LGPD.

B Glossário didático

AI/IA Inteligência Artificial.

PCCT Tomografia computadorizada por contagem de fótons (*photon-counting CT*).

Detector de contagem de fótons Detector semicondutor que converte cada fóton de raio X diretamente em sinal elétrico, contando-o e medindo sua energia.

Bin de energia Faixa de energia na qual os fótons detectados são classificados.

VMI Imagem monoenergética virtual, reconstruída como se o feixe tivesse uma única energia.

VNC Imagem virtual sem contraste, calculada removendo-se a contribuição do iodo.

Mapa de iodo Imagem paramétrica da concentração de iodo em mg/mL, usada como medida de perfusão.

Decomposição de materiais Separação da atenuação medida em contribuições de materiais de base.

DICOM Padrão para armazenamento e comunicação de imagens médicas.

HU Unidade Hounsfield, escala dos números de TC.

Radiômica Extração de grande número de atributos quantitativos de imagens médicas.

IBSI Iniciativa de padronização de biomarcadores de imagem.

RECIST Critério dimensional padronizado de avaliação de resposta em tumores sólidos.

ICC Coeficiente de correlação intraclasse, medida de reprodutibilidade.

Domain shift Mudança estatística entre os dados de treinamento e os dados encontrados em uso real.

OOD *Out-of-Distribution*; exame que difere significativamente do domínio conhecido pelo modelo.

Human-in-the-loop Processo em que o algoritmo auxilia, mas a revisão humana permanece parte explícita do fluxo.

SaMD *Software as a Medical Device*.